



**Politechnika
Śląska**

Sprawozdanie z modułu nr 1
MLA 2025/2026

**Aplikacje uczenia maszynowego
w systemach interakcji człowiek-maszyna**

Kierunek: Informatyka

Członkowie zespołu:

Piotr Skowroński

Kinga Grabarczyk

Irek Kosek

Krzysztof Czuba

Gliwice, 2025/2026

Spis treści

1	Wprowadzenie	2
1.1	Zakres tematyczny sprawozdania	2
1.2	Zespół projektowy	2
2	ML – zagadnienia teoretyczne	3
2.1	Wprowadzenie do części teoretycznej	3
2.2	Rozwinięcie	3
2.2.1	Przegląd paradygmatów ML	3
2.2.2	Szczegółowa analiza Uczenia ze Wzmocnieniem (RL)	3
2.2.3	Deep Reinforcement Learning	4
2.2.4	Exploration vs Exploitation	4
2.3	Podsumowanie części teoretycznej	4
3	ML – zagadnienia praktyczne	5
3.1	Wprowadzenie do części praktycznej	5
3.2	Rozwinięcie	5
3.2.1	Biblioteki i frameworki	5
3.2.2	Praktyczne zastosowania RL	5
3.2.3	Wyzwania praktyczne	5
3.3	Podsumowanie części praktycznej	5
4	Podsumowanie i wnioski	7
4.1	Podsumowanie	7
4.2	Wnioski	7
5	Spis literatury	8

1 Wprowadzenie

1.1 Zakres tematyczny sprawozdania

Niniejsze sprawozdanie stanowi realizację pierwiastka teoretycznego i praktycznego w zakresie identyfikacji i analizy aktualnego stanu dziedziny Uczenia Maszynowego (Machine Learning – ML). Dokument przedstawia ogólny przegląd głównych paradygmatów uczenia maszynowego, takich jak uczenie nadzorowane i nienadzorowane, ze szczególnym uwzględnieniem Uczenia ze Wzmocnieniem (Reinforcement Learning – RL).

Wybór RL jako głównego obszaru badawczego w ramach pracy zespołu projektowego wynika z jego rosnącego znaczenia w systemach autonomicznych i interakcji człowiek-maszyna. Sprawozdanie omawia teoretyczne podstawy algorytmów uczących się, a także praktyczne aspekty ich implementacji z wykorzystaniem nowoczesnych frameworków.

1.2 Zespół projektowy

- **Piotr Skowroński** – Lider zespołu – Koordynacja prac, analiza algorytmów RL
- **Kinga Grabarczyk** – Analityk treści – Analiza zagadnień teoretycznych, przygotowanie przeglądu paradygmatów uczenia maszynowego oraz opracowanie teorii metod uczenia
- **Irek Kosek** – Analityk danych – Zbieranie źródeł literaturowych, analiza wyników, dokumentacja
- **Krzysztof Czuba** – Specjalista ds. praktycznych – Analiza narzędzi i frameworków, przygotowanie sekcji praktycznej

2 ML – zagadnienia teoretyczne

2.1 Wprowadzenie do części teoretycznej

Uczenie maszynowe to obszar sztucznej inteligencji poświęcony algorytmom, które poprawiają swoje działanie poprzez doświadczenie. Zgodnie z aktualnym stanem dziedziny, wyróżniamy trzy główne paradygmaty uczenia, które znajdują zastosowanie w zależności od dostępności danych i zdefiniowanego problemu:

1. **Uczenie nadzorowane (Supervised Learning)** – oparte na danych etykietowanych, gdzie model uczy się mapowania wejścia na wyjście.
2. **Uczenie nienadzorowane (Unsupervised Learning)** – służące do odkrywania ukrytych struktur w danych nieetykietowanych.
3. **Uczenie ze wzmocnieniem (Reinforcement Learning)** – oparte na interakcji agenta ze środowiskiem w celu maksymalizacji nagrody.

Podstawowym modelem formalnym dla problemów decyzyjnych w ML, a w szczególności w RL, jest proces decyzyjny Markowa (MDP).

2.2 Rozwinięcie

W celu pełnego opracowania stanu dziedziny, poniżej scharakteryzowano krótko klasyczne podejścia, by następnie przejść do pogłębionej analizy uczenia ze wzmocnieniem.

2.2.1 Przegląd paradygmatów ML

Uczenie nadzorowane jest najczęściej stosowanym podejściem w biznesie. Obejmuje zadania *klasyfikacji* (przypisywanie danych do dyskretnych kategorii) oraz *regresji* (przewidywanie wartości ciągłych). Wymaga ono zbioru treningowego zawierającego poprawne odpowiedzi (etykiety). Popularne algorytmy to m.in. maszyny wektorów nośnych (SVM) czy głębokie sieci neuronowe.

Uczenie nienadzorowane nie wykorzystuje etykiet. Jego celem jest znalezienie wzorców w danych, np. poprzez *klasteryzację* (grupowanie podobnych obiektów) lub redukcję wymiarowości (np. PCA). Jest kluczowe w eksploracyjnej analizie danych.

2.2.2 Szczegółowa analiza Uczenia ze Wzmocnieniem (RL)

Jako główny przedmiot badań w tym projekcie, RL wyróżnia się brakiem nadzoru w postaci gotowych etykiet. Agent uczy się poprzez metodę prób i błędów. Wyróżniamy tu następujące kluczowe podejścia:

Metody oparte na wartości (Value-Based Methods) Q-Learning jest podstawowym algorytmem uczenia ze wzmocnieniem, który uczy się funkcji wartości akcji $Q(s, a)$. Algorytm aktualizuje wartości Q zgodnie z równaniem Bellmana:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[R + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

gdzie α to współczynnik uczenia, a γ współczynnik dyskontowania przyszłych nagród. SARSA to alternatywa typu on-policy, która aktualizuje wartości na podstawie rzeczywistie wykonanej akcji.

Metody oparte na polityce (Policy-Based Methods) Policy Gradient Methods bezpośrednio optymalizują parametryzowaną politykę poprzez gradient wznoszenia. Algorytmy takie jak REINFORCE czy Actor-Critic łączą zalety metod wartości i polityki.

2.2.3 Deep Reinforcement Learning

Połączenie klasycznego ML (sieci neuronowe) z RL dało początek Deep RL. **Deep Q-Network (DQN)** łączy Q-Learning z głębokimi sieciami neuronowymi, co umożliwia radzenie sobie z problemami o dużej przestrzeni stanów. Kluczowe innowacje DQN to experience replay oraz target network. **Proximal Policy Optimization (PPO)** to nowoczesny algorytm, który osiąga balans między wydajnością uczenia a stabilnością.

2.2.4 Exploration vs Exploitation

Fundamentalnym dylematem w RL jest balans między eksploracją (poznawaniem nowych akcji) a eksploatacją (wykorzystywaniem znanej wiedzy). Popularne strategie to epsilon-greedy oraz Upper Confidence Bound (UCB).

2.3 Podsumowanie części teoretycznej

Analiza stanu dziedziny wskazuje na dynamiczny rozwój wszystkich gałęzi uczenia maszynowego. Podczas gdy uczenie nadzorowane dominuje w analizie danych statycznych, uczenie ze wzmocnieniem (wsparte głębokimi sieciami neuronowymi) staje się kluczową technologią w systemach decyzyjnych i robotyce. Teoretyczne podstawy obejmujące MDP, funkcje wartości i polityki znajdują zastosowanie w szerokim spektrum dziedzin.

3 ML – zagadnienia praktyczne

3.1 Wprowadzenie do części praktycznej

Praktyczne zastosowania uczenia maszynowego wymagają wykorzystania zaawansowanych narzędzi programistycznych. W tej sekcji prezentujemy przegląd istniejących bibliotek oraz systemów, ze szczególnym uwzględnieniem tych wspierających algorytmy RL.

3.2 Rozwinięcie

3.2.1 Biblioteki i frameworki

Współczesne uczenie maszynowe opiera się na potężnych bibliotekach numerycznych, takich jak **TensorFlow** (opracowany przez Google) czy **PyTorch**. Stanowią one bazę dla tworzenia sieci neuronowych (CNN, RNN) i są fundamentem dla specjalistycznych narzędzi RL:

OpenAI Gym to standardowa platforma do tworzenia i testowania algorytmów RL. Oferuje szeroki zestaw środowisk testowych i definiuje ujednolicony interfejs API.

Stable Baselines3 to zbiór implementacji najnowocześniejszych algorytmów RL (A2C, PPO, SAC, TD3) w PyTorch. Biblioteka oferuje wysoki poziom abstrakcji i łatwość użycia.

TensorFlow Agents (TF-Agents) to modułowa biblioteka do budowania, trenowania i ewaluacji algorytmów RL w ekosystemie TensorFlow.

Ray RLlib to skalowalna biblioteka dla rozproszonego uczenia ze wzmocnieniem, umożliwiająca trening na wielu maszynach.

3.2.2 Praktyczne zastosowania RL

Gry i rozrywka: AlphaGo od DeepMind oraz OpenAI Five pokazują możliwości RL w złożonych grach strategicznych.

Robotyka: RL jest szeroko stosowany do uczenia manipulacji obiektami, chodu robotów oraz planowania trajektorii (np. Boston Dynamics).

Autonomiczne pojazdy: Firmy takie jak Waymo i Tesla wykorzystują RL do trenowania systemów podejmowania decyzji w ruchu drogowym.

Systemy rekomendacyjne: Netflix i YouTube wykorzystują RL do personalizacji treści w celu maksymalizacji zaangażowania użytkowników.

Optymalizacja zasobów: Zastosowanie w zarządzaniu zużyciem energii w centrach danych (Google).

3.2.3 Wyzwania praktyczne

Sample efficiency – algorytmy RL często wymagają milionów interakcji ze środowiskiem. **Stabilność uczenia** – wyzwanie związane z niestacjonarnością danych i bootstrappingiem. **Bezpieczeństwo i etyka** – kluczowe w aplikacjach krytycznych (np. pojazdy autonomiczne, medycyna).

3.3 Podsumowanie części praktycznej

Ekosystem narzędzi ML i RL rozwinął się znacząco, oferując gotowe implementacje w bibliotekach takich jak Stable Baselines3 czy TF-Agents. Praktyczne zastosowania obejmują

mują szerokie spektrum dziedzin, od gier po optymalizację biznesową. Pomimo sukcesów, wyzwania związane z efektywnością i bezpieczeństwem pozostają kluczowymi obszarami dalszych prac inżynierskich.

4 Podsumowanie i wnioski

4.1 Podsumowanie

Uczenie Maszynowe, w tym Reinforcement Learning, stanowi dynamicznie rozwijający się obszar AI. W sprawozdaniu przedstawiono fundamenty teoretyczne obejmujące główne paradygmaty uczenia (nadzorowane, nienadzorowane, RL) oraz szczegółowo omówiono mechanizmy RL (MDP, Q-Learning, PPO). Część praktyczna ukazała bogaty ekosystem narzędzi (TensorFlow, OpenAI Gym) oraz ich realne wdrożenia.

4.2 Wnioski

Po przeprowadzeniu analizy teoretycznej i praktycznej można sformułować następujące wnioski:

1. Uczenie maszynowe oferuje uniwersalne metody rozwiązywania problemów klasyfikacji i regresji, podczas gdy RL jest niezastąpiony w problemach sekwencyjnego podejmowania decyzji.
2. Integracja algorytmów RL z głębokim uczeniem (Deep RL) pozwala na rozwiązywanie problemów o wysokiej złożoności, choć wiąże się to z wyzwaniami stabilności treningu.
3. Dostępność gotowych bibliotek (np. Stable Baselines3) obniża próg wejścia, ale skuteczne wdrożenie wymaga zrozumienia teoretycznych podstaw algorytmów.
4. Przyszłość dziedziny leży w rozwoju technik takich jak meta-learning, offline RL oraz bezpieczne AI, co pozwoli na szersze zastosowanie w systemach krytycznych.
5. Rozwój systemów interakcji człowiek-maszyna będzie w coraz większym stopniu polegał na adaptacyjnych algorytmach uczących się preferencji użytkownika.

5 Spis literatury

Literatura

- [1] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [2] Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533.
- [3] Silver, D., Huang, A., Maddison, C. J., et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), 484–489.
- [4] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- [5] Brockman, G., Cheung, V., Pettersson, L., et al. (2016). OpenAI Gym. *arXiv preprint arXiv:1606.01540*.
- [6] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268), 1–8.
- [7] Watkins, C. J., & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3-4), 279–292.
- [8] Lillicrap, T. P., Hunt, J. J., Pritzel, A., et al. (2015). Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*.
- [9] Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *International Conference on Machine Learning*, 1861–1870.
- [10] Vinyals, O., Babuschkin, I., Czarnecki, W. M., et al. (2019). Grandmaster level in StarCraft II using multi-agent reinforcement learning. *Nature*, 575(7782), 350–354.