



**Politechnika
Śląska**

Dokumentacja projektowa

MLA 2025/2026

**Aplikacje uczenia maszynowego
w systemach interakcji człowiek-maszyna**

Kierunek: Informatyka
Specjalność: Uczenie Maszynowe
Stopień: II

Członkowie zespołu:
Piotr Skowroński - Lider Zespołu i Specjalista LaTeX
Krzysztof Czuba - Inżynier ML
Kinga Grabarczyk - Inżynier Danych
Irek Kosek - Specjalista HCI

Gliwice, 2025/2026

Spis treści

1	Wprowadzenie	2
1.1	Cel projektu	2
1.2	Zespół projektowy	2
2	Założenia projektowe	3
2.1	Koncepcja i Mapa Myśli	3
2.2	Zbiór danych i transformacje	3
2.2.1	Charakterystyka zbioru danych	3
2.2.2	Transformacje i augmentacja	4
3	Implementacja	5
3.1	Architektura modelu	5
3.1.1	Opis architektury U-Net	5
3.1.2	Konfiguracja modelu w MONAI	5
3.2	Proces treningowy	6
3.2.1	Funkcja straty — Dice Loss	6
3.2.2	Konfiguracja procesu uczenia	7
4	Badania	8
4.1	Metryki ilościowe	8
4.1.1	Dice Coefficient (Współczynnik Dice / F1-Score)	8
4.1.2	Intersection over Union (IoU / Jaccard Index)	8
4.1.3	Wyniki eksperymentalne	9
4.2	Analiza wizualna	9
5	Podsumowanie i wnioski	12
6	Spis literatury	13

1 Wprowadzenie

Niniejsza dokumentacja opisuje projekt zespołowy realizowany w ramach przedmiotu Aplikacje uczenia maszynowego w systemach interakcji człowiek-maszyna". Projekt skupia się na problemie segmentacji obrazów medycznych w celu wykrywania zmian nowotworowych płuc.

1.1 Cel projektu

Głównym celem jest opracowanie i wytrenowanie modelu głębokiego uczenia, który pozwoli na automatyczne wyodrębnienie obszarów zajętych chorobą ze skanów tomografii komputerowej (CT). System ma służyć jako interaktywne wsparcie dla radiologa, przyspieszając proces diagnostyczny.

1.2 Zespół projektowy

Imię i Nazwisko 1 :: Inżynier ML :: Implementacja modelu MONAI UNet, pętla treningowa, ewaluacja metryk.


Imię i Nazwisko 2 :: Specjalista HCI :: Projektowanie interfejsu interakcji, analiza Mapy Myśli, dokumentacja.

2 Założenia projektowe

Projekt realizowany jest zgodnie z metodyką Project-based learning, uwzględniając analizę źródeł naukowych dotyczących głębokich sieci splotowych w medycynie.

2.1 Koncepcja i Mapa Myśli

Proces konceptualizacji projektu został utrwalony w formie mapy myśli, uwzględniającej aspekty techniczne (ML) oraz użytkowe (HCI).



Rysunek 1: Mapa myśli procesu konceptualizacji projektu.

2.2 Zbiór danych i transformacje

W projekcie wykorzystano publicznie dostępny zbiór danych **Lung Cancer Segmentation Dataset** pochodzący z platformy Kaggle. Dataset składa się z 3000 par obrazów: skanów tomografii komputerowej (CT) płuc oraz odpowiadających im masek segmentacyjnych przygotowanych przez ekspertów radiologów.

2.2.1 Charakterystyka zbioru danych

- **Źródło:** Kaggle - Lung Cancer Segmentation Dataset.
- **Liczba próbek:** 3000 par (obraz CT + maska ekspercka).
- **Format obrazów:** Pliki graficzne w skali szarości.
- **Typ adnotacji:** Binarne maski segmentacyjne oznaczające obszary zmian nowotworowych.
- **Podział danych:** 70% trening, 20% walidacja, 10% test.

2.2.2 Transformacje i augmentacja

Zastosowano następujące transformacje danych w celu przygotowania ich do procesu uczenia:

- **Normalizacja intensywności:** Skalowanie wartości pikseli do zakresu $[0, 1]$ w celu stabilizacji procesu uczenia.
- **Augmentacja geometryczna:** Losowa rotacja o wielokrotność 90 stopni (prawdopodobieństwo $p=0.5$) w celu zwiększenia różnorodności danych treningowych i redukcji przeuczenia.
- **Konwersja typów:** Transformacja do tensorów PyTorch typu float32.

3 Implementacja

3.1 Architektura modelu

W projekcie wykorzystano architekturę **U-Net**, która została zaproponowana przez Ronnebergera i współpracowników w 2015 roku specjalnie do zadań segmentacji obrazów biomedycznych.

3.1.1 Opis architektury U-Net

Architektura U-Net charakteryzuje się symetryczną strukturą w kształcie litery „U”, składającą się z dwóch głównych części:

- **Ścieżka kurczenia (Encoder/Contracting Path):** Lewa strona sieci odpowiedzialna za ekstrakcję cech. Składa się z powtarzających się bloków: dwóch warstw konwolucyjnych 3x3 z aktywacją ReLU, po których następuje warstwa max pooling 2x2. Na każdym poziomie liczba kanałów cech jest podwajana, co pozwala na wychwytywanie coraz bardziej abstrakcyjnych reprezentacji obrazu.
- **Ścieżka ekspansji (Decoder/Expanding Path):** Prawa strona sieci odpowiedzialna za rekonstrukcję przestrzenną. Wykorzystuje warstwy up-convolution (transpozycja konwolucyjna) 2x2 w celu zwiększenia rozdzielczości, połączone z odpowiadającymi mapami cech ze ścieżki kurczenia poprzez mechanizm *skip connections*.
- **Skip Connections:** Kluczowy element architektury, który łączy odpowiadające poziomy enkodera i dekodera. Umożliwia to zachowanie szczegółowych informacji przestrzennych, które są traczone podczas operacji pooling, co jest szczególnie istotne dla precyzyjnej lokalizacji granic segmentowanych obiektów.

3.1.2 Konfiguracja modelu w MONAI

Wykorzystano implementację UNet z biblioteki MONAI (Medical Open Network for AI) o następujących parametrach:

- **Wymiary przestrzenne:** 2D (`spatial_dims=2`).
- **Kanały wejściowe:** 1 (obrazy w skali szarości).
- **Kanały wyjściowe:** 1 (binarna maska segmentacyjna).

- **Struktura kanałów:** (16, 32, 64, 128, 256) — liczba filtrów na kolejnych poziomach.
- **Strides:** (2, 2, 2, 2) — krok redukcji przestrzennej między poziomami.

3.2 Proces treningowy

3.2.1 Funkcja straty — Dice Loss

W zadaniach segmentacji obrazów medycznych często występuje problem niezrównoważenia klas — obszary zmian chorobowych zajmują znacznie mniejszą część obrazu niż tło. Klasyczna funkcja straty cross-entropii w takich przypadkach może prowadzić do słabych wyników. Z tego powodu zastosowano funkcję straty **Dice Loss**.

Dice Loss jest bezpośrednio powiązana ze współczynnikiem Dice (Dice Coefficient) i definiowana jest jako:

$$\text{Dice Loss} = 1 - \frac{2 \sum_{i=1}^N p_i \cdot g_i + \epsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N g_i + \epsilon} \quad (1)$$

gdzie:

- p_i — wartość predykcji dla piksela i (po aktywacji sigmoid),
- g_i — wartość ground truth dla piksela i (0 lub 1),
- N — całkowita liczba pikseli,
- ϵ — mały współczynnik wygładzający (smooth factor) zapobiegający dzieleniu przez zero.

Zalety Dice Loss:

- Naturalna odporność na niezrównoważenie klas.
- Bezpośrednia optymalizacja metryki używanej do ewaluacji.
- Lepsza konwergencja dla obiektów o małej powierzchni.

3.2.2 Konfiguracja procesu uczenia

Model trenowano z użyciem następujących parametrów:

- **Optymalizator:** Adam z początkowym tempem uczenia $lr = 0.001$.
- **Funkcja straty:** DiceLoss z aktywacją sigmoid.

- **Scheduler:** ReduceLROnPlateau — dynamiczna redukcja tempa uczenia o czynnik 0.1 przy braku poprawy przez 10 epok.
- **Liczba epok:** 400.
- **Rozmiar batcha:** 64.
- **Early stopping:** Monitorowanie validation loss z cierpliwością 30 epok.

4 Badania

Ewaluacja modelu została przeprowadzona na wydzielonym zbiorze testowym (10% danych).

4.1 Metryki ilościowe

4.1.1 Dice Coefficient (Współczynnik Dice / F1-Score)

Współczynnik Dice, znany również jako Sørensen-Dice coefficient lub F1-Score dla segmentacji, jest jedną z najczęściej stosowanych metryk do oceny jakości segmentacji obrazów medycznych. Mierzy on podobieństwo między predykcją modelu a ground truth.

Współczynnik Dice definiowany jest jako:

$$\text{Dice} = \frac{2 \cdot |P \cap G|}{|P| + |G|} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (2)$$

gdzie:

- P — zbiór pikseli zaklasyfikowanych jako pozytywne (predykcja),
- G — zbiór pikseli ground truth (maska ekspercka),
- TP — true positives (poprawnie wykryte piksele zmiany),
- FP — false positives (błędnie wykryte piksele jako zmiana),
- FN — false negatives (pominięte piksele zmiany).

Wartość Dice mieści się w przedziale $[0, 1]$, gdzie 1 oznacza idealne dopasowanie.

4.1.2 Intersection over Union (IoU / Jaccard Index)

IoU (Intersection over Union), znany również jako indeks Jaccarda, jest kolejną fundamentalną metryką w segmentacji obrazów. Mierzy stosunek części wspólnej do sumy zbiorów predykcji i ground truth.

IoU definiowany jest jako:

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|} = \frac{TP}{TP + FP + FN} \quad (3)$$

Relacja między Dice a IoU: Obie metryki są ze sobą powiązane matematycznie:

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}} \Leftrightarrow \text{IoU} = \frac{\text{Dice}}{2 - \text{Dice}} \quad (4)$$

Dice zawsze przyjmuje wartości wyższe lub równe IoU dla tego samego przypadku, ponieważ bardziej premiuje część wspólną.

4.1.3 Wyniki eksperymentalne


Wyniki uzyskane na zbiorze testowym (300 obrazów, 10% całego zbioru) prezentują się następująco:

- **Average Dice Coefficient: 0.77** — dobry poziom zgodności segmentacji.
- **Average Intersection over Union (IoU): 0.68** — solidne pokrycie obszarów zmian.
- **Average Recall: 0.80** — wysoka czułość wykrywania zmian nowotworowych.
- **Average Precision: 0.78** — dobra precyzja z niskim poziomem fałszywych alarmów.


Interpretacja wyników: Uzyskany współczynnik Dice na poziomie 0.77 wskazuje, że model poprawnie identyfikuje około 77% obszaru zmiany nowotworowej przy jednoczesnym zachowaniu niskiego poziomu fałszywie pozytywnych predykcji. Wysoki Recall (0.80) jest szczególnie istotny w kontekście diagnostyki medycznej, gdzie pominięcie zmiany nowotworowej może mieć poważne konsekwencje kliniczne.

4.2 Analiza wizualna

Poniżej przedstawiono przebieg funkcji straty oraz przykładowe predykcje modelu na tle masek wzorcowych.



Rysunek 2: Wykresy funkcji straty dla zbioru treningowego i walidacyjnego.



Rysunek 3: Wizualizacja predykcji: Obraz oryginalny, Ground Truth, Predykcja oraz Nałożenie.

5 Podsumowanie i wnioski

- **Podsumowanie:** W ramach projektu pomyślnie wytrenowano model UNet z biblioteki MONAI na zbiorze 3000 obrazów CT. Model osiągnął satysfakcjonujące wyniki metryczne: współczynnik Dice na poziomie 0,77 oraz IoU równy 0,68. Proces treningu (400 epok) przebiegał stabilnie, co potwierdzają wygenerowane wykresy funkcji straty, wykazujące zbieżność zarówno na zbiorze treningowym, jak i walidacyjnym.
- **Wnioski techniczne (ML):** Wysoka wartość metryki Recall (0,80) w stosunku do Precision (0,78) sugeruje, że model jest dobrze zoptymalizowany pod kątem czułości diagnostycznej. W badaniach przesiewowych raka płuc priorytetem jest minimalizacja wyników fałszywie ujemnych, co udało się osiągnąć. Analiza map różnicowych (Difference Maps) wskazuje, że ewentualne błędy wynikają głównie z trudności w precyzyjnym wyznaczaniu granic mniejszych zmian nowotworowych.
- **Wnioski HCI:** Zastosowanie nakładek wizualnych (Overlay Comparison) oraz map prawdopodobieństwa stanowi kluczowy element interakcji człowiek-maszyna. Pozwala to radiologowi na błyskawiczną weryfikację obszarów wskazanych przez algorytm, co w praktyce klinicznej może skrócić czas opisu badania przy jednoczesnym zachowaniu wysokiej czułości diagnostycznej.

6 Spis literary