



**Politechnika
Śląska**

Dokumentacja projektowa

MLA 2025/2026

**Aplikacje uczenia maszynowego
w systemach interakcji człowiek-maszyna**

Kierunek: Informatyka

Specjalność: Uczenie Maszynowe

Stopień: II

Członkowie zespołu:

Piotr Skowroński - Lider Zespołu i Specjalista LaTeX

Krzysztof Czuba - Inżynier ML

Kinga Grabarczyk - Inżynier Danych

Irek Kosek - Specjalista HCI

Gliwice, 2025/2026

Spis treści

1	Wprowadzenie	2
1.1	Cel projektu	2
1.2	Zespół projektowy	2
2	Założenia projektowe	3
2.1	Koncepcja i Mapa Myśli	3
2.2	Zbiór danych i transformacje	3
3	Implementacja	4
3.1	Architektura modelu	4
3.2	Proces treningowy	4
4	Badania	5
4.1	Metryki ilościowe	5
4.2	Analiza wizualna	5
5	Podsumowanie i wnioski	8
6	Spis literatury	9

1 Wprowadzenie

Niniejsza dokumentacja opisuje projekt zespołowy realizowany w ramach przedmiotu Aplikacje uczenia maszynowego w systemach interakcji człowiek-maszyna". Projekt skupia się na problemie segmentacji obrazów medycznych w celu wykrywania zmian nowotworowych płuc.

1.1 Cel projektu

Głównym celem jest opracowanie i wytrenowanie modelu głębokiego uczenia, który pozwoli na automatyczne wyodrębnienie obszarów zajętych chorobą ze skanów tomografii komputerowej (CT). System ma służyć jako interaktywne wsparcie dla radiologa, przyspieszając proces diagnostyczny.

1.2 Zespół projektowy

Imię i Nazwisko 1 :: Inżynier ML :: Implementacja modelu MONAI UNet, pętla treningowa, ewaluacja metryk.


Imię i Nazwisko 2 :: Specjalista HCI :: Projektowanie interfejsu interakcji, analiza Mapy Myśli, dokumentacja.

2 Założenia projektowe

Projekt realizowany jest zgodnie z metodyką Project-based learning, uwzględniając analizę źródeł naukowych dotyczących głębokich sieci splotowych w medycynie.

2.1 Koncepcja i Mapa Myśli

Proces konceptualizacji projektu został utrwalony w formie mapy myśli, uwzględniającej aspekty techniczne (ML) oraz użytkowe (HCI).



Rysunek 1: Mapa myśli procesu konceptualizacji projektu.

2.2 Zbiór danych i transformacje

Wykorzystano zbiór 3000 par obrazów (skany płuc i maski eksperckie). Zastosowano następujące transformacje danych:

- Skalowanie intensywności do zakresu $[0, 1]$.
- Augmentacja: losowa rotacja o wielokrotność 90 stopni ($p=0.5$).
- Standaryzacja rozmiaru przestrzennego do 512x512 pikseli.

3 Implementacja

3.1 Architektura modelu

Wykorzystano architekturę **UNet** z biblioteki MONAI o następujących parametrach:

- Wymiary przestrzenne: 2D.
- Kanały wejściowe/wyjściowe: 1.
- Struktura kanałów: (16, 32, 64, 128, 256) ze strefami kroku (strides) równymi 2.
- Jednostki rezydualne: 2 na każdym poziomie.

3.2 Proces treningowy

Model trenowano z użyciem optymalizatora Adam ($lr = 0.001$) oraz funkcji straty **DiceLoss** z aktywacją sigmoid. Zastosowano mechanizm *ReduceLROnPlateau* do dynamicznej regulacji tempa uczenia.

4 Badania

Ewaluacja modelu została przeprowadzona na wydzielonym zbiorze testowym (10% danych).


4.1 Metryki ilościowe

Wyniki uzyskane na zbiorze testowym prezentują się następująco:


- **Average Dice Coefficient: 0.77**
- **Average Intersection over Union (IoU): 0.68**
- Average Recall: 0.80
- Average Precision: 0.78

4.2 Analiza wizualna

Poniżej przedstawiono przebieg funkcji straty oraz przykładowe predykcje modelu na tle masek wzorcowych.



Rysunek 2: Wykresy funkcji straty dla zbioru treningowego i walidacyjnego.



Rysunek 3: Wizualizacja predykcji: Obraz oryginalny, Ground Truth, Predykcja oraz Nałożenie.

5 Podsumowanie i wnioski

- **Podsumowanie:** W ramach projektu pomyślnie wytrenowano model UNet z biblioteki MONAI na zbiorze 3000 obrazów CT. Model osiągnął satysfakcjonujące wyniki metryczne: współczynnik Dice na poziomie 0,77 oraz IoU równy 0,68. Proces treningu (400 epok) przebiegał stabilnie, co potwierdzają wygenerowane wykresy funkcji straty, wykazujące zbieżność zarówno na zbiorze treningowym, jak i walidacyjnym.
- **Wnioski techniczne (ML):** Wysoka wartość metryki Recall (0,80) w stosunku do Precision (0,78) sugeruje, że model jest dobrze zoptymalizowany pod kątem czułości diagnostycznej. W badaniach przesiewowych raka płuc priorytetem jest minimalizacja wyników fałszywie ujemnych, co udało się osiągnąć. Analiza map różnicowych (Difference Maps) wskazuje, że ewentualne błędy wynikają głównie z trudności w precyzyjnym wyznaczaniu granic mniejszych zmian nowotworowych.
- **Wnioski HCI:** Zastosowanie nakładek wizualnych (Overlay Comparison) oraz map prawdopodobieństwa stanowi kluczowy element interakcji człowiek-maszyna. Pozwala to radiologowi na błyskawiczną weryfikację obszarów wskazanych przez algorytm, co w praktyce klinicznej może skrócić czas opisu badania przy jednoczesnym zachowaniu wysokiej czułości diagnostycznej.

6 Spis literary