

Segmentacja obrazu w wykrywaniu raka płuc

ML w systemach interakcji człowiek-maszyna

P. Skowroński, K. Czuba, K. Grabarczyk, I. Kosek

Politechnika Śląska
Wydział Matematyki Stosowanej


Rok akademicki 2025/2026

Projekt realizowany zgodnie z metodyką *Project-based learning*

- **Piotr Skowroński** – Lider zespołu, dokumentacja LaTeX.
- **Krzysztof Czuba** – Inżynier ML (Implementacja modelu).
- **Kinga Grabarczyk** – Inżynier Danych (Metryki i preprocessing).
- **Irek Kosek** – Specjalista HCI (Projekt interfejsu Streamlit).

Konceptualizacja projektu

Proces opracowania założeń projektu zespołowego oparto o Mapę Myśli



Rysunek: Struktura koncepcyjna.

Lung Cancer Segmentation Dataset (Kaggle)

- **3000 par obrazów:** skany CT płuc + maski eksperckie
- **Format:** obrazy w skali szarości, binarne maski segmentacyjne
- **Podział:** 70% trening / 20% walidacja / 10% test

Transformacje danych:

- Normalizacja intensywności do zakresu $[0, 1]$
- Augmentacja: rotacja o wielokrotność 90 ($p=0.5$)

Wykorzystanie źródeł o charakterze naukowym

- **Architektura:** U-Net (Ronneberger et al., 2015).
- **Framework:** MONAI (Medical Open Network for AI).

Symetryczna struktura w kształcie litery „U”:

- **Encoder (ścieżka kurczenia):**

- Ekstrakcja cech przez warstwy konwolucyjne 3×3 + ReLU
- Max pooling 2×2 — redukcja rozdzielczości
- Podwajanie liczby kanałów na każdym poziomie


- **Decoder (ścieżka ekspansji):**

- Up-convolution 2×2 — zwiększanie rozdzielczości
- Rekonstrukcja przestrzenna segmentacji

- **Skip Connections:**

- Łączenie odpowiadających poziomów encoder-decoder
- Zachowanie szczegółów przestrzennych dla precyzyjnych granic

Schemat architektury U-Net



Rysunek: Schemat architektury U-Net (Ronneberger et al., 2015).


Implementacja modelu (ML)

Konfiguracja MONAI UNet:

- Wymiary: 2D
- Wejście/Wyjście: 1 kanał
- Kanały: (16, 32, 64, 128, 256)
- Strides: (2, 2, 2, 2)

Trening:

- Adam ($lr = 0.001$)
- 400 epok, batch=64



Rysunek: Przebieg procesu uczenia.

Problem: Niezrównoważenie klas — zmiany nowotworowe $\ll$ tło

Rozwiązanie: Dice Loss — odporna na niezrównoważenie klas

$$\text{Dice Loss} = 1 - \frac{2 \sum p_i \cdot g_i + \epsilon}{\sum p_i + \sum g_i + \epsilon}$$

Zalety:

- Bezpośrednia optymalizacja metryki ewaluacyjnej
- Lepsza konwergencja dla małych obiektów
- Naturalna odporność na dominację klasy tła

Dice Coefficient (F1-Score):

$$\text{Dice} = \frac{2 \cdot |P \cap G|}{|P| + |G|}$$

- Mierzy podobieństwo predykcji do ground truth
- Zakres: $[0, 1]$, gdzie 1 = idealne dopasowanie

IoU (Jaccard Index):

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|}$$

- Stosunek części wspólnej do sumy zbiorów
- Bardziej rygorystyczna niż Dice

Relacja: $\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}}$ — $\text{Dice} \geq \text{IoU}$


Ewaluacja na zbiorze testowym (300 obrazów = 10% zbioru):

Metryka	Wartość	Interpretacja
Dice Coefficient	0.77	Dobra zgodność segmentacji
IoU (Jaccard)	0.68	Solidne pokrycie zmian
Recall (Czułość)	0.80	Wysoka czułość diagnostyczna
Precision	0.78	Niski poziom fałszywych alarmów

Wniosek: Wysoki Recall (0.80) jest kluczowy w diagnostyce medycznej — minimalizacja pominięć zmian nowotworowych.


System interakcji (HCI)

- Interaktywne wgrywanie plików.
- Wizualizacja masek i Probability Maps.



Rysunek: Interfejs systemu wspomagania diagnostyki.

Wizualizacja wyników segmentacji



Rysunek: Porównanie: Oryginał vs Ground Truth vs Predykcja. ▶

- Opracowano kompletny scenariusz diagnostyczny.
- Zintegrowano zaawansowane ML z interfejsem wspierającym lekarza.